

# DESARROLLO DE UN MARCO DE PLANIFICACIÓN TERRITORIAL PARA LA EDUCACIÓN SUPERIOR

USO DE MODELOS DE APRENDIZAJE AUTOMÁTICO Y ANÁLISIS GEOESPACIAL PARA LA EXPANSIÓN DE LA EDUCACIÓN SUPERIOR EN LÍNEA. CASO DE APLICACIÓN EN LA UNIVERSIDAD POLITÉCNICA SALESIANA

6 de enero de 2026

Christian Rolando Oyola FLORES

Master Universitario en Ciencia de Datos (Data Science)

# AGENDA

El Desafío: (Contexto, Problema y Objetivos)

Marco Ético

Solución: Metodología y Modelos

Resultados: Territorialización

Conclusiones y Trabajo Futuro

Bibliografía


## **EL DESAFÍO: (CONTEXTO, PROBLEMA Y OBJETIVOS)**

## CONTEXTO: LA EXPANSIÓN Y LA DIVERSIDAD

La expansión a modalidades **en línea o híbridas** permite ampliar el alcance sin depender de infraestructura física. Esto incorpora estudiantes con realidades **sociodemográficas y tecnológicas diversas**:

- ▶ Edad, ocupación, composición familiar.
- ▶ **Pluralidad cultural y discapacidad.**

La población objetivo deja de ser homogénea y se vuelve un conjunto de **perfiles distintos**.




# EL PROBLEMA: EXPANSIÓN REACTIVA VS. CENTROS APOYO

La expansión reactiva es ineficiente. La propuesta es un marco de **posicionamiento territorial** basado en perfiles para acercar la oferta mediante **centros de apoyo híbridos**.

- **Objetivo:** Asignación anticipada de recursos.
- **Foco:** Nichos no saturados y segmentos específicos.

Esto fortalece la diferenciación y orienta la expansión con una lógica de planificación basada en evidencia.



# OBJETIVOS: LAS PREGUNTAS CLAVE

La propuesta busca responder a tres preguntas fundamentales para la planificación estratégica:

- ▶ **1. Patrones de Perfil:** ¿Cuáles son los patrones conductuales, socioeconómicos y de conectividad tecnológica de los estudiantes de la modalidad en línea?
- ▶ **2. Similitud Territorial:** ¿Qué unidades administrativas locales LAU2 (cantones) son similares con los perfiles de la institución?
- ▶ **3. Gaps de Cobertura:** ¿Cuales son los gaps o espacios de cobertura óptimos para este posicionamiento considerando accesibilidad territorial y tiempos de desplazamiento?

**Objetivo Principal:** Planificación basada en evidencia para la asignación anticipada de recursos y la priorización de segmentos específicos.

**MARCO ÉTICO**


---

Universitat  
Oberta  
de Catalunya

---

# MARCO ÉTICO: ALINEACIÓN GLOBAL


La propuesta se alinea con el marco IIPE-UNESCO y la Agenda Educación 2030, asumiendo la equidad y la inclusión como criterios rectores [1].





## **SOLUCIÓN: METODOLOGÍA Y MODELOS**

# SOLUCIÓN: ARQUITECTURA ANALÍTICA



## Flujo Reproducible

Integración de perfiles institucionales con microdatos censales para una **inferencia territorial** escalable y precisa. *Nota:*

*El escalamiento mediante modelos supervisados permite proyectar hallazgos de la muestra al universo nacional.*

# SOLUCIÓN: ARQUITECTURA ANALÍTICA





Figura: Arquitectura técnica de la propuesta

# METODOLOGÍA: ESTANDAR CRISP-DM

Adaptación del estándar de minería de datos Cross-Industry Standard Process for Data Mining 1.0 (CRISP-DM) para garantizar un proceso **reproducible y escalable** en el contexto educativo [2].


- Comprensión del Dominio y Datos.
- **Preparación de Datos** (Crítica).
- Modelado y Evaluación.
- Despliegue.



**Figura:** Framework CRISP-DM 1.0, adaptado al contexto educativo

# PREPARACIÓN DE DATOS INSTITUCIONALES

- ▶ **Limpieza y Dicotomización:** Síntesis de variables de responsabilidad familiar y discapacidad.
- ▶ **Análisis de Asociación:** Uso de **V de Cramer** para categóricas y **Spearman** para continuas/ordinales.
- ▶ **Resultado:** Dataset optimizado de 375 registros con 14 variables clave (Educación, Ocupación, TIC, Vivienda).



# EL DESAFÍO: VARIABLES MIXTAS

Los perfiles se componen de variables de distinta naturaleza, lo que impide el uso de distancias tradicionales:

- ▶ **Numéricas:** Edad.
- ▶ **Categorías Nominales:** Ocupación, Estado Civil.
- ▶ **Ordinales:** Nivel de Instrucción (requiere respetar el orden).
- ▶ **Dicotómicas:** ¿Trabaja?, ¿Tiene hijos?

?

¿Cómo medimos la similitud de forma coherente?

# LA SOLUCIÓN: DISTANCIA DE GOWER PONDERADA

La métrica de Gower permite combinar la disimilitud de variables mixtas, tratando cada tipo de dato de forma adecuada [3, 4].

$$d(x_i, x_k) = \frac{\sum_{j=1}^p w_j \delta_{ijk} d_j(x_i, x_k)}{\sum_{j=1}^p w_j \delta_{ijk}} \quad (1)$$

donde:

- ▶  $d(x_i, x_k)$ : distancia de Gower ponderada entre las observaciones  $i$  y  $k$
- ▶  $p$ : número total de variables en el conjunto de datos
- ▶  $w_j$ : peso asignado a la variable  $j$  (con  $\sum_{j=1}^p w_j = 1$ )
- ▶  $\delta_{ijk}$ : función indicadora que toma el valor de 1 si ambas observaciones  $i$  y  $k$  tienen valores válidos (no missing) en la variable  $j$ , y 0 en caso contrario
- ▶  $d_j(x_i, x_k)$ : distancia normalizada entre las observaciones  $i$  y  $k$  para la variable  $j$ , definida como:
  - ▶ Variables cuantitativas:  $d_j(x_i, x_k) = \frac{|x_{ij} - x_{kj}|}{R_j}$  donde  $R_j$  es el rango de la variable  $j$
  - ▶ Variables categóricas:  $d_j(x_i, x_k) = \begin{cases} 0 & \text{si } x_{ij} = x_{kj} \\ 1 & \text{si } x_{ij} \neq x_{kj} \end{cases}$

# EJEMPLO: CALCULANDO LA DISTANCIA DE GOWER

## Comparando dos estudiantes:

| Variable     | María        | Juan     |
|--------------|--------------|----------|
| Edad         | 28 años      | 35 años  |
| Educación    | Licenciatura | Maestría |
| Ocupación    | Ingeniera    | Chef     |
| Internet     | Sí           | Sí       |
| Estado civil | Soltera      | Casado   |

## Distancias individuales $d_j$ :

1. **Edad** (cuantitativa):  $d = \frac{|28-35|}{65-18} = \frac{7}{47} = 0,15$
2. **Educación** (ordinal):  $d = \frac{|3-4|}{5} = 0,20$
3. **Ocupación** (categórica):  $d = 1$  (diferentes)
4. **Internet** (dicotómica):  $d = 0$  (iguales)
5. **Estado civil** (categórica):  $d = 1$  (diferentes)

## Pesos asignados ( $w_j$ ):

| Variable     | Peso | $d_j$ |
|--------------|------|-------|
| Edad         | 0.20 | 0.15  |
| Educación    | 0.40 | 0.20  |
| Ocupación    | 0.20 | 1.00  |
| Internet     | 0.10 | 0.00  |
| Estado civil | 0.10 | 1.00  |

## Cálculo final:

Numerador:

$$\begin{aligned}
 &= (0,20)(0,15) + (0,40)(0,20) \\
 &\quad + (0,20)(1,00) + (0,10)(0,00) \\
 &\quad + (0,10)(1,00) \\
 &= 0,030 + 0,080 + 0,200 \\
 &\quad + 0,000 + 0,100 = \mathbf{0,410}
 \end{aligned}$$

Denominador:  $\sum w_j = 1,0$

$$d(\text{María, Juan}) = \frac{0,410}{1,0} = \mathbf{0,41}$$



## PONDERACIÓN INTELIGENTE (NMI)

Utilizamos la **Información Mutua Normalizada (NMI)** para definir de forma objetiva los pesos de las variables [4].

- ▶ **Prioridad al Capital Humano:** El Nivel de Instrucción recibe un peso mayor por ser un atributo estructural de largo plazo.
- ▶ **Ajuste Experto:** Evita clústers superficiales basados solo en activos materiales (ejemplo: tener auto).
- ▶ **Resultado:** Un esquema de pesos que favorece la identificación de segmentos académicos reales.

# EL PROCESO DE CLUSTERING (HCA)

- **Algoritmo:** Agrupamiento Jerárquico Aglomerativo (HCA) [5, 6].
- **Validación:** Uso de criterios internos para determinar la partición óptima.
- **Resultado:** Identificación de tres perfiles (etiquetas) que representan la población objetivo.




Figura: Proyección t-SNE de la segmentación final

## **RESULTADOS: TERRITORIALIZACIÓN**





---

Universitat  
Oberta  
de Catalunya

---

# RESULTADOS: TRES PERFILES NÍTIDOS



La separación más nítida se observa en la condición de empleo y el capital académico, coherente con el vector de pesos asignado.

## PERFILES IDENTIFICADOS

### Perfil 0: Estudiante Típico (62.5 %)

- ▶ **Edad:** Mediana 26 años.
- ▶ **Educación:** Bachillerato (Educación Media).
- ▶ **Empleo:** Mayoría trabaja.
- ▶ **Conectividad:** Alta.
- ▶ **Vivienda:** Predomina el alquiler.

Perfil de entrada y volumen, buscando ascenso social.

**Co**  
“Jóvenes Trabajadores”

## PERFILES IDENTIFICADOS

### Perfil 1: Profesional conectado (20.2 %)

- ▶ **Edad:** Mediana 30 años (hasta 68).
- ▶ **Educación:** Superior / Posgrado.
- ▶ **Empleo:** 100 % trabaja.
- ▶ **Conectividad:** 94 % Alta (el más conectado).
- ▶ **Poder Adquisitivo:** Mayor vivienda propia y auto.

Objetivo clave para posgrados

**C1**  
“Profesionales”

## PERFILES IDENTIFICADOS

### Perfil 2: Estudiantes en Transición (17.3 %)

- ▶ **Edad:** Mediana 21 años.
- ▶ **Género:**  $\approx 90$  % Mujeres.
- ▶ **Empleo:** 100 % No trabaja.
- ▶ **Conectividad:** Alta (64 %).
- ▶ **Carga Familiar:** Baja (78 %).

Nicho ideal para enfoque de becas

**C2**  
“Estudiantes en Transición”

# CLASIFICACIÓN (ALGORITMO SUPERVISADO)


El modelo supervisado permite escalar los perfiles sobre los datos del censo poblacional del INEC.

- ▶ **Predicción:** Asignación de etiquetas a individuos no etiquetados.
- ▶ **Densidad:** Identificación de cantones con alta concentración de perfiles específicos.
- ▶ **Estrategia:** Localización de centros de apoyo en nichos no saturados



# MODELO SUPERVISADO: ENTRENAMIENTO Y VALIDACIÓN

## Pipeline de Entrenamiento




## Desempeño del Modelo

Métricas en conjunto de prueba (n=69):


- ▶ Accuracy: **0.72**
- ▶ Macro F1-Score: **0.72**
- ▶ Kappa de Cohen: **0.59** (acuerdo moderado)

## Matriz de Confusión




# PREDICCIÓN MASIVA

## Arquitectura de Datos INEC




**Conversión:** CSV → PostgreSQL → Parquet (Azure)

## Clasificación Masiva



## Indicador de Confianza



Mayor confianza → Predicciones robustas sobre 8.1M

Demostración Práctica TFM

## **CONCLUSIONES Y TRABAJO FUTURO**

Universitat  
Oberta  
de Catalunya

# CONCLUSIONES



# CONCLUSIONES

## Propuesta frente a lo convencional

- ▶ Mientras que la ejecución de encuestas nacionales implicaría costos logísticos masivos y un retraso de al menos un año, esta propuesta ofrece una solución instantánea precisa y escalable sobre datos Censales ya existentes.
- ▶ A diferencia de un mapeo reactivo de la competencia —que suele saturar nichos ya atendidos—, este modelo detecta demanda potencial priorizando sectores rurales, basándose en la identidad institucional.
- ▶ Asimismo, al ser un desarrollo propio, permite realizar una transferencia de conocimiento interna que las consultorías externas no ofrecen, constituyéndose como un activo estratégico permanente y replicable que evoluciona junto con la realidad institucional y del país.

# VISIÓN DE FUTURO

## Ecosistema para la interculturalidad

- ▶ La infraestructura de datos debe actualizarse constantemente, integrando nuevas fuentes de información sobre servicios básicos, discapacidad y pobreza.
- ▶ El objetivo final es la interculturalización radical de la educación superior: romper con el modelo de aula digital como un canal de contenidos homogeneizados para convertirla en un espacio de encuentro.
- ▶ Al utilizar variables de autoidentificación étnica y lenguas ancestrales dentro del núcleo del modelo, aseguramos que la planificación no invisibilice a los pueblos originarios, sino que respete sus historias y visiones de mundo.
- ▶ No buscamos transformar a las poblaciones en objetos de estudio, sino en protagonistas de una expansión educativa que sea, ante todo, un acto de justicia social y pertinencia territorial.

## **BIBLIOGRAFÍA**

---

Universitat  
Oberta  
de Catalunya

---



## BIBLIOGRAFIA I

- [1] UNESCO-IIEP. *International Institute for Educational Planning*.  
<https://www.iiep.unesco.org/id>. Accedido: 01-dic-2025. 2025.
- [2] J. Luis y col. «CRISP-EDM: uma proposta de adaptação do Modelo CRISP-DM para mineração de dados educacionais». En: *Simpósio Brasileiro de Informática na Educação (SBIE)*. [cited 2025 Oct 7]. Nov. de 2020, págs. 1092-1101. URL: <https://sol.sbc.org.br/index.php/sbie/article/view/12865>.
- [3] J. C. Gower. «A General Coefficient of Similarity and Some of Its Properties». En: *Biometrics* 27 (4 1971), pág. 857. ISSN: 0006341X. DOI: 10.2307/2528823.
- [4] Pinyan Liu y col. «A modified and weighted Gower distance-based clustering analysis for mixed type data: a simulation and empirical analyses». En: *BMC Medical Research Methodology* 24.1 (2024), pág. 305.

## BIBLIOGRAFÍA II

- [5] Keefe Murphy, Sonsoles López-Pernas y Saqr. «Dissimilarity-Based Cluster Analysis of Educational Data: A Comparative Tutorial Using R». En: *Learning Analytics Methods and Tutorials: A Practical Guide Using R*. Springer Nature Switzerland, 2024, págs. 231-283. DOI: 10.1007/978-3-031-54464-4\_8. URL: [https://doi.org/10.1007/978-3-031-54464-4\\_8](https://doi.org/10.1007/978-3-031-54464-4_8).
- [6] James E. Corter. «Clustering approaches». En: *International Encyclopedia of Education (Fourth Edition)*. Ed. por Robert J Tierney, Fazal Rizvi y Kadriye Ercikan. Fourth Edition. Oxford: Elsevier, 2023, págs. 627-636. ISBN: 978-0-12-818629-9. DOI: <https://doi.org/10.1016/B978-0-12-818630-5.10072-7>. URL: <https://www.sciencedirect.com/science/article/pii/B9780128186305100727>.

# ACCESO DISPONIBLE AL REPOSITORIO



Gracias por su atención

Universitat  
Oberta  
de Catalunya